

Relatório de Análise de Saúde de Repositórios GitHub

Disciplina: TELP

Discente: Rafael Santana

1. Introdução

Este relatório tem como objetivo avaliar a "saúde" de três repositórios do GitHub, com saúdes pretensiosamente diferentes, utilizando um conjunto de métricas inspiradas nos frameworks DORA, SPACE e Developer Thriving. As métricas selecionadas consideram tanto a produtividade das equipes quanto o envelhecimento e a importância dos projetos.

Os repositórios analisados foram:

PandasAI: Integra inteligência artificial ao pandas, permitindo consultas e análises de dados. Repositório relativamente novo e com pouca atividade recente, indicando possível abandono.

Polars: Biblioteca de DataFrames em Rust voltada para processamento de dados rápido e eficiente, similar ao pandas. Repositório intermediário, com atividade constante, mas moderada.

PyTorch: Biblioteca de aprendizado de máquina em Python, focada em redes neurais e computação acelerada com GPU. Repositório mais antigo, com alto nível de contribuições até os dias atuais e com a maior quantidade de commits.

2. Metodologia

A análise foi feita com base em dados obtidos via Git e scripts em Python através do plotly e o próprio pandas para geração de gráficos. As métricas foram organizadas visando o foco gerencial em dois grandes grupos:

2.1 Métricas de Envelhecimento

Número de commits por ano/mês

Concentração de commits por autor

Tempo desde o último commit

Idade do repositório

2.2 Métricas de Importância

Principais contribuidores

Commits por contribuidor


Número de arquivos alterados com frequência

3. PandasAI

O repositório PandasAI apresenta características típicas de um projeto relativamente jovem e displicente. Através do maior contribuidor do projeto, verificador por:

```
# lista os 20 maiores committers com nome e e-mail
!git shortlog -sn --email --no-merges | head -n 20 | tee users-commit.txt
```


Foi utilizada a análise da quantidade de commits por ano/mês do maior autor:



Revela uma curva de atividade bastante concentrada em um curto período inicial de um ano, com poucos picos de atualização ao longo do tempo, provavelmente por alguma nova implementação ou correção de bugs. Isso sugere um projeto que recebeu atenção pontual no início, e não possui uma rotina consistente de manutenção ou evolução, sem falar que nos períodos mais atuais ele se encontra sem muitos novos commits, já que pelo código git:


```
!git-bars -p day -a '2025-01-01' -b '2025-05-20' -u "lele.venturi@gmail.com"
```

Consegue-se observar que no ano atual, de 2025, até o dia 20/05 foram realizados apenas 65 novos commits, reforçando ainda mais essa linha de raciocínio, de um projeto flertando com o abandono.



Outro fator relevante de se pontuar é a concentração de commits por autor, que evidencia uma forte dependência de poucos colaboradores o que levanta preocupações sobre a resiliência do projeto a longo prazo. Projetos com alta concentração em poucos autores é sinal de risco de sustentabilidade. No PandasAI isso foi observado através do primeiro script citado no relatório que também nos entrega a quantidade de commits por autor.


Top 9 Committers: Distribuição de Commits



Através desse gráfico fica claro inferir uma tremenda concentração de autores no projeto, já que Gabriele Venturi <lele.venturi@gmail.com>, possui quase 65% da contribuição total e o segundo maior autor Arslan Saleem <khan.arslan38@gmail.com>, que também contribuiu através de outros e-mails, possui mais de 20% de contribuição, sendo assim 80% do projeto concentra-se em apenas 2 autores, justificando a possível causa da não durabilidade e sustentabilidade do projeto.

Por fim, a análise dos arquivos frequentemente alterados (churn) mostra um escopo limitado de modificação, muitos commits em poucos arquivos pode ser sinal de possível problema estrutural. Isso pode indicar tanto uma base de código estática quanto uma falta de evolução nas funcionalidades.

Top 20 Arquivos Mais Alterados (Churn)




4. Polars

O repositório Polars representa um projeto em crescimento e com sinais claros de maturidade. A análise do número de commits por ano e por mês do maior autor demonstra uma trajetória ascendente e sustentada, com estabilidade de atividade ao longo do tempo, sinalizando um esforço contínuo de desenvolvimento e manutenção. Consultando o maior autor também pelo código:

```
# lista os 20 maiores committers com nome e e-mail
!git shortlog -sn --email --no-merges | head -n 20 | tee users-commit.txt
```


Pode-se perceber através do gráfico, feito com plotly, que demonstra uma seriedade e uma complexidade maior que no PandasAI, tendo em vista a quantidade de commits do maior autor, Ritchie Vink <ritchie46@gmail.com>, ser bastante superior ao último projeto analisado, demonstrando um compromisso maior:



Vale ressaltar também que esse projeto não se qualifica como um projeto que tende ao abandono, já que utilizando do mesmo código anterior, verificando a atividade do maior autor, e tendo conhecimento de que esse autor não só contribuiu por esse e-mail


```
!git-bars -p day -a '2025-01-01' -b '2025-05-20' -u "ritchie46@gmail.com"
```

Consegue-se observar que no ano atual, de 2025, até o dia 20/05, foram realizados 176 novos commits, deixando ainda mais visível essa narrativa de um projeto com atividade recente, o tempo desde o último commit é curto, reforçando que o projeto está ativo.



Dando continuidade a essa análise, tomando em base a metodologia, a distribuição de commits por autor é mais equilibrada no Polars em relação ao PandasAI, o que sugere um núcleo de desenvolvimento mais colaborativo e menos concentrado. Porém ainda assim, há uma predominância de alguns desenvolvedores-chave, característica comum em projetos de médio porte.

Top 10 Committers: Distribuição de Commits



Nesse gráfico consegue-se visualizar que o maior colaborador do projeto, Ritchie Vink, compartilha de duas contas com os maiores números de commits do repositório, totalizando cerca de 60% do projeto total nas mãos de uma só pessoa. Comparando com o repositório anterior, realmente é um número menor de concentração, já que a autora principal do PandasAI carregava 65% de todo projeto, porém também é válido ressaltar que no repositório anterior o top 7 commiter do projeto não passava de 20 commits:

```
# lista os 20 maiores committers com nome e e-mail
!git shortlog -sn --email --no-merges | head -n 20 | tee users-commit.txt

666 Gabriele Venturi <lele.venturi@gmail.com>
134 Arslan Saleem <khan.arslan38@gmail.com>
51 ArslanSaleem <khan.arslan38@gmail.com>
50 Raoul Scalise <36519284+scaliseraoul@users.noreply.github.com>
46 Massimiliano Pronesti <massimiliano.pronesti@gmail.com>
34 Ihor <31508183+nautics889@users.noreply.github.com>
18 Henrique Branco <henrique.ajnbranco@gmail.com>
```

Em contrapartida, no Polars, o top 8 committers do projeto passaram dos 400 commits:

```
# lista os 20 maiores committers com nome e e-mail
!git shortlog -sn --email --no-merges | head -n 20 | tee users-commit.txt

4845 Ritchie Vink <ritchie46@gmail.com>
994 ritchie46 <ritchie46@gmail.com>
891 Alexander Beedie <alexander-beedie@users.noreply.github.com>
609 Stijn de Gooijer <stijndegooijer@gmail.com>
597 Stijn de Gooijer <stijn@degooijer.io>
425 Orson Peters <orsonpeters@gmail.com>
420 nameexhaustion <simonlin.rqmmw@slmail.me>
413 Gijs Burghoorn <me@gburghoorn.com>
```

Realizando uma conta matemática básica, pegando a quantidade maior de commits do maior autor e dividindo pela quantidade de commits do menor autor temos no Polars:

$$4845 / 413 = 11,7x$$


No PandasAI

$$666 / 18 = 37x$$

Ou seja, fica-se claro que no Polars a concentração de autores foi significativamente menor já que no PandasAI, a relação entre o trabalho do menor e maior autor analisado foi de 37 vezes mais.

Por fim, os arquivos frequentemente alterados revelam quais módulos ou funcionalidades estão sendo mais desenvolvidos ou corrigidos. No caso do Polars, há uma boa diversidade de arquivos em constante modificação, indicando evolução ativa e modularidade, consequentemente com um projeto bem mais equilibrado em relação ao último analisado.

Top 20 Arquivos Mais Alterados (Churn)



5. Pytorch

Dentre os 3 repositórios o PyTorch possui a maior contribuição quando se fala sobre quantidades de commits, é um exemplo clássico de projeto consolidado e o mais “saúdável” dos projetos analisados, reforçando a ideia de que se as métricas postas na metodologia fossem seguidas, obteriam os mesmos êxitos do projeto mais antigo e mais bem consolidado. O maior contribuinte também foi acessado pelo código:

```
# lista os 20 maiores committers com nome e e-mail
!git shortlog -sn --email --no-merges | head -n 20 | tee users-commit.txt
```

Porém nesse projeto em específico surgiu algo curioso, o maior commiter foi: PyTorch MergeBot <pytorchmergebot@users.noreply.github.com>, um bot levando o maior número de commits em um repositório que tem como objetivo machine learning. Sendo assim, analisando o segundo maior commiter, Edward Z. Yang, para tratar-se de uma análise pessoal de fato, obtemos o gráfico utilizando da análise da quantidade de commits por ano/mês do maior autor:

Obs: Aparentemente a maioria dos contribuidores relevantes são funcionários da Meta, popularmente conhecida como Facebook, após o ano de 2022, em meados de 2023 vários autores trocaram o endereço de e-mail de @fb.com para @meta.com com a mudança do nome da empresa. Devido a isso, possui-se uma base de dados para autores pré mudança e pós mudança de e-mail. Porém analisando rapidamente é perceptível que Edward Z. Yang é de fato o maior humano contribuinte para o projeto com 3 contas e totalizando 3046 commits.

```
3351 PyTorch MergeBot <pytorchmergebot@users.noreply.github.com>
1202 Nikita Shulga <nshulga@fb.com>
1121 Edward Z. Yang <ezyang@meta.com>
1119 Edward Yang <ezyang@fb.com>
991 Richard Zou <zou3519@gmail.com>
970 Jerry Zhang <jerryzh@fb.com>
889 Peter Bell <peterbell10@live.co.uk>
870 Adam Paszke <adam.paszke@gmail.com>
855 Gregory Chanan <gchanan@fb.com>
835 cyy <cyever@outlook.com>
806 Edward Z. Yang <ezyang@fb.com>
749 Michael Suo <suo@fb.com>
720 Animesh Jain <anijain@umich.edu>
679 Rohan Varma <rvarm1@fb.com>
645 Nikita Shulga <nshulga@meta.com>
```

Gráfico de atividade Edward FB






Gráfico de atividade Edward Meta




Tomando por base os dois gráficos, percebe-se que o autor teve picos essenciais no início do projeto, porém por agora ele não está se enveredando tanto, tendo possíveis interpretações, já que o projeto está longe de ser abandonado, foram cerca de 8000 commits adicionados desde de quando esse relatório foi iniciado, há cerca de duas semanas atrás. Tendo em vista também que essas métricas são mais eficazes quando utilizadas em repositórios que pecam no quesito de time engajado e concentração de trabalho.

Nesse projeto mesmo fica claro que a distribuição de participação é bem equilibrada:

Top 10 Committers: Distribuição de Commits




Top 10 Committers: Distribuição de Commits



No segundo gráfico, onde temos o bot retirado do escopo, nenhum autor passa dos 15% de contribuição total do projeto, é importante lembrar que Edward Yang possui 3 contas nesse gráfico que totalizaria 30%, porém comparado com os outros projetos cujo os maiores contribuidores passavam de 60% de atribuições, os dados de commits por ano/mês do Pytorch mostram uma volumetria impressionante e constante, reflexo de uma base de usuários ampla e uma comunidade de desenvolvedores engajada.


Por fim, a análise dos arquivos frequentemente alterados não deixa tão clara uma estrutura altamente dinâmica. Muitos arquivos são modificados regularmente, evidenciando um ciclo contínuo de desenvolvimento e manutenção que acompanha as demandas de uma base global de usuários, mas é visível sim, uma possível concentração de número de alterações em poucos arquivos.

Top 20 Arquivos Mais Alterados (Churn)




6. Comparativo Final da Saúde dos Repositórios

Atividade de Commits ao Longo do Tempo



Atividade de Commits ao Longo do Tempo



O gráfico comparativo de atividade de commits ao longo do tempo evidencia de forma clara o contraste entre os três projetos analisados. O PyTorch se destaca com uma volumetria de commits significativamente superior, refletindo sua longa trajetória, alta relevância e forte engajamento comunitário. É um projeto consolidado, com contribuição contínua e distribuída, sustentando sua posição como o mais “saudável” entre os avaliados.


O Polars aparece como um intermediário, tanto em tempo de existência quanto em volume e consistência de commits.

Por outro lado, o PandasAI revela-se o mais frágil dos três. Seu gráfico mostra uma atividade concentrada nos primeiros meses e quase nenhuma movimentação nos períodos mais recentes, apontando para um possível abandono. Além disso, o baixo número de colaboradores ativos acentua esse diagnóstico.

Esse panorama visual reforça as conclusões obtidas pelas métricas analisadas: projetos saudáveis mantêm uma cadência de desenvolvimento, contam com uma base colaborativa distribuída e refletem, em seus commits, a vitalidade da comunidade que os sustenta.

Visualmente, o gráfico deixa evidente a disparidade entre os três projetos. A linha do PyTorch sobe de forma abrupta, com milhares de commits por ano; o Polars cresce de forma mais linear e saudável; enquanto o PandasAI mal ultrapassa a linha de base, refletindo seu estágio incipiente e possível estagnação.

Disparidade de Commits entre Autores por Repositório



A visualização apresentada acima busca representar de maneira inovadora a concentração de commits entre os principais contribuidores dos três repositórios analisados: PandasAI, Polars e PyTorch. Utilizou-se um gráfico de funil invertido, que é uma forma eficaz de destacar quedas bruscas ou diferenças progressivas em dados hierárquicos, neste caso, o número de commits entre o maior autor e um dos autores subsequentes.

Para cada repositório, foram comparados os commits realizados pelo autor com o maior número de contribuições e outro autor que figura entre os principais contribuidores (top 6, 8 ou 10, dependendo do repositório). Essa escolha não aleatória, foi devida a uma determinada quantidade de commits que seria relevante. Essa comparação permite observar o nível de concentração de atividade de desenvolvimento.

PandasAI: O gráfico mostra uma queda extremamente acentuada, saindo de 666 commits (Gabriele Venturi) para 18 commits (Henrique Branco) 7º, evidenciando uma razão de 37x. Essa concentração extrema levanta preocupações quanto à dependência crítica de um único desenvolvedor.

Polars: A diferença entre o principal autor (4845 commits – Ritchie Vink) e o 8º mais ativo (413 commits – Gijs Burghoorn) é de 11,7x, uma disparidade significativa, porém menos extrema que a observada no PandasAI.

PyTorch: Mostra a maior uniformidade, com o principal autor (Edward Yang – 3046 commits) contribuindo apenas 4,5x mais que o 10º colocado (Rohan Varma – 679 commits). Isso indica uma distribuição mais saudável e equilibrada de esforço entre os contribuidores do projeto.

7. Conclusão

Este relatório apresentou uma análise abrangente da saúde de três repositórios GitHub por meio de métricas de envelhecimento e importância. Através da observação de padrões de commits, concentração de autores e evolução dos arquivos, foi possível identificar diferentes estágios de maturidade e engajamento comunitário entre os projetos. O PyTorch destacou-se como o mais robusto e sustentável, o Polars mostrou um desenvolvimento ativo e promissor, enquanto o PandasAI revelou sinais de possível estagnação. Com isso, conclui-se que o uso sistemático de métricas pode ser uma ferramenta eficaz na avaliação da vitalidade de projetos de software, porém com algumas limitações, já que muitos desses métodos utilizaram de métricas quantitativas, algo completamente burlável.